

[Multivariate Analysis 최종 보고서]

기상 조건이 강원도 화재 발생 및 피해 규모에 미치는 영향 분석

: PCA 기반 포아송 GLM과 상호작용 MLR을 이용한 빈도·심도 통합 모델링

과목명: Multivariate Analysis (IMEN 415)

제출일: 2026년 6월 10일

작성자:

2021170814 류근호 (산업경영공학부)

2022340019 이용준 (심리학과 / 산업경영공학부)

2020170857 이준혁 (산업경영공학부)

고려대학교 / 산업경영공학부

1. Introduction

1.1 연구 배경 및 동기

강원도는 태백산맥을 경계로 영동과 영서 지역으로 나뉘며, 각기 다른 기후 특성을 가진다. 특히 봄철에는 태백산맥을 넘어 영동 지방으로 불어오는 고온 건조한 바람인 **양간지풍(일명 뽕 현상)**이 발생하여 화재 위험을 높이는 것으로 알려져 있다(기상청 강원지방기상청, 한국 지역별 기후특성). 실제로 2019년 4월 고성·속초 산불은 약 2,000ha의 산림을 소실시키고 2명이 사망하였으며(행정안전부, 2019), 2022년 3월 울진·삼척 산불은 약 16,302ha의 산림 피해를 입혀 특별재난지역으로 선포되었다(산림청, 2022). 이러한 대형 화재들은 강한 바람과 건조한 기상 조건이 복합적으로 작용한 결과로 분석된다.

기후변화로 인해 강수 패턴과 기온이 변화하면서 화재 발생 시기와 규모 또한 변화하고 있다는 우려가 제기되고 있다. 따라서 기상 조건과 화재 발생 간의 통계적 관계를 규명하고, 지역별 특성을 고려한 분석이 필요하다.

1.2 연구 목적 및 질문

본 연구는 2015년부터 2024년까지 10년간의 강원도 화재 데이터와 기상 관측 데이터를 결합하여, 기상 조건이 화재 **발생 빈도(frequency)**와 **피해 규모(severity)**에 미치는 영향을 통계적으로 분석하는 것을 목적으로 한다. 구체적인 연구 질문은 다음과 같다.

1. 기상 변수들의 복합적 요인(주성분)과 계절은 화재 발생 빈도에 유의한 영향을 미치는가?
2. 영동과 영서 지역 간에 풍속이 화재 피해 규모에 미치는 영향은 다른가? 즉, 양간지풍에 해당하는 지형-풍속 간 상호작용 효과가 존재하는가?

1.3 데이터 소개

본 연구에서는 두 가지 공공 데이터를 활용하였다.

화재 데이터는 소방청 공공데이터포털(국가화재정보시스템)에서 제공하는 화재 발생 정보로, 2015년부터 2024년까지 강원도 18개 시군구에서 발생한 화재 기록을 포함한다. 각 화재 건에 대한 발생 일시, 시도·시군구, 인명피해 소계, 재산피해 소계 정보를 담고 있다. 본 연구에서 '화재'는 소방청이 집계하는 모든 유형(건축물, 임야, 자동차, 기타)을 포함하며, 서론에서 사례로 언급한 '산불'은 임야 화재의 일부에 해당한다.

기상 데이터는 기상청 기상자료개방포털에서 제공하는 종관기상관측(ASOS) 일자료로, 강원도 내 관측소의 기온(평균·최저·최고), 강수량, 풍속(평균·최대), 습도(평균·최소) 등을 포함한다. 이 가운데 분석에 직접 투입한 연속형 변수는 평균기온·평균습도·최대풍속이며, 여기에 일교차(기온교차 = 최고기온 - 최저기온)와 건조지수(기온·습도 기반 파생 변수)를 추가로 생성하여 총 5개 변수를 주성분 분석에 사용하였다(자세한 내용은 2.1절 참조).

두 데이터는 동일한 기간(2015~2024)과 지역(강원도)을 대상으로 하며, 각각 공신력 있는 공공기관에서 수집된 자료로 신뢰성이 확보된다.

1.4 분석 방법 개요

본 연구는 다음 절차를 따른다. 먼저 두 이종(heterogeneous) 데이터를 '날짜-시군구' 단위로 결합하여 시공간 패널 데이터를 구축한다. 이후 두 가지 통계 분석을 수행한다.

가설 1에서는 기상 변수 간 다중공선성을 완화하기 위해 **주성분 분석(PCA)**으로 기상 패턴을 소수의 독립적 지수로 축약하고, 화재 발생 **건수**라는 카운트 자료의 특성을 반영하여 **일반화 선형 모델(GLM)**중 포아송 회귀를 적합한다. 이 과정에서 수업에서 다룬 로지스틱 회귀를 우선 검토한 뒤 그 한계를 보완하는 방향으로 모델을 발전시킨다. 가설 2에서는 **다중선형회귀(MLR)**에 풍속과 지역(영동/영서)의 **상호작용 항**을 추가하여, 지형에 따라 풍속의 효과가 달라지는지를 검정한다.

1.5 본 연구의 기여 (Our Contributions)

산불과 기상에 관한 기존 연구는 개별 기상 변수와 화재 간 단순 상관관계를 보거나 기상학적 메커니즘을 규명하는 데 집중한 경우가 많았다. 본 연구는 다음 네 가지 측면에서 차별성을 가진다. 첫째, 10년 치 자료를 '날짜-시군구' 단위로 정합시켜 단면 분석이 아닌 시공간 패널 데이터를 구축하였다. 둘째, 기상 변수 간 다중공선성을 주성분 분석(PCA)으로 완화하고 해석 가능한 기상 지수를 도출하였다. 셋째, 화재 발생 '여부(0/1)' 대신 '건수'를 종속변수로 하는 포아송 GLM을 채택하여 다발성 위험을 모델링하였다. 넷째, Cook's Distance로 기상과 무관한 극단 피해를 정제한 뒤 상호작용 회귀로 지형 효과를 검정하였다. 각 기여의 구체적 근거는 해당 가설의 분석 절에서 다시 설명한다.

2. Analysis

2.1 데이터 전처리 요약

분석에 사용할 자료는 '날짜(Date)-시군구(Location)'를 공통 키로 하는 **시공간 패널 데이터**로 구축하였다. 전처리는 크게 (i) 인코딩 처리 및 변수 표준화, (ii) 이중 데이터 결합, (iii) 결측·이상치 정제, (iv) 파생 변수 생성의 네 단계로 이루어진다.

화재 원자료는 연도별로 분리·제공되며 한글 인코딩(CP949) 문제가 있어, 파일을 읽을 때 인코딩을 지정하고 컬럼명을 표준화한 뒤 강원도 자료만 필터링하였다. 이후 '날짜-시군구' 단위로 화재 건수와 재산피해액을 집계하였다. 기상 자료 역시 CP949 인코딩으로 인한 컬럼명 깨짐을 방지하기 위해 컬럼을 인덱스 기준으로 재명명하였고, 관측소별 결측치는 선형 보간(na.approx)과 직전·직후값 대체(na.locf)로 처리하였다. 마지막으로 시군구-관측소 매핑 후 '날짜 × 18개 시군구' 전체 격자에 결합하여 화재가 없는 날에도 기상 정보가 유지되는 완전한 패널을 구성하였다.

```
# ——— 경로 설정 ———
base_dir <- "C:/Users/docto/Desktop/다변량/final project/data"
fire_dir   <- file.path(base_dir, "fire")           # 연도별 화재 CSV 폴더
weather_path <- file.path(base_dir, "weather/weather_data.csv") # 기상 ASOS 파일

# 천 단위 쉼표 제거 후 숫자 변환 헬퍼
to_num <- function(x) suppressWarnings(as.numeric(gsub(",", "", as.character(x))))

# (1) 화재: 연도별 CSV(2015~2024) 통합 → 강원도 → 날짜-시군구 집계
fire_files <- list.files(path = fire_dir, pattern = "^20\\W\\Wd{2}\\W\\W.csv$", full.names = TRUE)
stopifnot(length(fire_files) > 0)

fire_list <- lapply(fire_files, function(file) {
  df <- read.csv(file, fileEncoding = "CP949", stringsAsFactors = FALSE, check.names = FALSE)
  names(df) <- str_replace_all(names(df), "화재발생년월일", "일시")
  names(df) <- str_replace_all(names(df), "시·군·구|시_군_구", "시군구")
  names(df) <- str_replace_all(names(df), "인명피해\\W\\W(명\\W\\W)소계", "인명피해소계")
  df[, c("일시", "시도", "시군구", "인명피해소계", "사망", "부상", "재산피해소계")]
})
fire_raw <- bind_rows(fire_list)

fire_agg <- fire_raw %>%
  filter(str_detect(시도, "강원")) %>%
  mutate(
    Date      = as.Date(parse_date_time(일시, orders = c("Ymd HM", "Ymd HMS", "Ymd"))),
    인명피해소계 = coalesce(to_num(인명피해소계), 0),
    사망       = coalesce(to_num(사망), 0),
    부상      = coalesce(to_num(부상), 0),
```

```

    재산피해소계 = coalesce(to_num(재산피해소계), 0)
  ) %>%
  group_by(Date, 시군구) %>%
  summarise(화재건수 = n(),
    인명피해 = sum(인명피해소계), 사망 = sum(사망),
    부상 = sum(부상), 재산피해 = sum(재산피해소계),
    .groups = "drop")

# (2) 기상: 인덱스 기반 재명명 + 관측소별 결측 보간
weather_raw <- read.csv(weather_path, fileEncoding = "CP949", stringsAsFactors = FALSE)
colnames(weather_raw)[1:11] <- c("지점", "지점명", "Date", "평균기온", "최저기온", "최고기온",
  "강수량", "최대풍속", "평균풍속", "최소습도", "평균습도")
weather <- weather_raw %>%
  mutate(Date = as.Date(Date),
    across(c(평균기온, 최고기온, 최저기온, 평균습도, 최대풍속, 강수량), to_num),
    강수량 = coalesce(강수량, 0)) %>% # 무강수일 = 0
  group_by(지점명) %>% arrange(Date) %>%
  mutate(across(c(평균기온, 최고기온, 최저기온, 평균습도, 최대풍속),
    ~ na.locf(na.locf(na.approx(x, na.rm = FALSE), na.rm = FALSE),
      fromLast = TRUE, na.rm = FALSE)))) %>%
  ungroup() %>%
  select(지점명, Date, 평균기온, 최고기온, 최저기온, 강수량, 평균습도, 최대풍속)

# (3) 시군구-관측소 매핑 + 전체 격자(날짜 × 18개 시군구) 결합
mapping <- data.frame(
  시군구 = c("속초시", "고성군", "양양군",
    "춘천시", "홍천군", "화천군", "양구군", "인제군",
    "철원군", "평창군",
    "원주시", "횡성군", "영월군",
    "강릉시", "동해시", "삼척시",
    "태백시", "정선군"),
  지점명 = c(rep("속초", 3), rep("춘천", 5), "철원", "대관령",
    rep("원주", 3), rep("강릉", 3), rep("태백", 2)),
  stringsAsFactors = FALSE
)
all_dates <- seq(as.Date("2015-01-01"), as.Date("2024-12-31"), by = "day")
full_grid <- expand.grid(Date = all_dates, 시군구 = mapping$시군구, stringsAsFactors = FALSE)

gangwon_panel <- full_grid %>%
  left_join(mapping, by = "시군구") %>%
  left_join(weather, by = c("Date", "지점명")) %>%
  left_join(fire_agg, by = c("Date", "시군구"))

```

이후 분석에 필요한 파생 변수를 생성하였다. 일교차(기온교차)는 최고기온과 최저기온의 차이로, 건조지수는 기온·습도를 결합한 건조도 지표(평균기온 - 평균습도/10)로 정의하였다. 또한 봄·여름·가을·겨울을 구분하는 계절 변수(계절)와, 시군구를 태백산맥 기준 영동/영서로 구분하는 지역 변수(Region)를 추가하였다. 회귀에 사용하는 봄철 더미(isSpring)는 2.3절에서 계절로부터 생성한다.

```

yeongdong <- c("강릉시", "동해시", "속초시", "삼척시", "고성군", "양양군")

gangwon_panel <- gangwon_panel %>%
  mutate(
    화재건수 = coalesce(화재건수, 0),
    인명피해 = coalesce(인명피해, 0), 사망 = coalesce(사망, 0),

```

```

부상    = coalesce(부상, 0),    재산피해 = coalesce(재산피해, 0),

화재발생여부 = ifelse(화재건수 > 0, 1, 0),
건조지수 = 평균기온 - (평균습도 / 10),    # 기온·습도 기반 건조도 지표
기온교차 = 최고기온 - 최저기온,          # 일교차
강수여부 = ifelse(강수량 > 0, 1, 0),

월      = month(Date),
계절    = case_when(
  월 %in% c(3, 4, 5) ~ "봄",
  월 %in% c(6, 7, 8) ~ "여름",
  월 %in% c(9, 10, 11) ~ "가을",
  TRUE ~ "겨울"
),
Region = ifelse(시군구 %in% yeongdong, "Yeongdong", "Yeongseo")
)

# (선택) 패널 산출물 저장
write.csv(gangwon_panel, "gangwon_panel.csv", row.names = FALSE, fileEncoding = "CP949")

```

2.2 탐색적 데이터 분석 (EDA)

본격적인 모형 적합에 앞서, 구축한 패널 데이터의 규모와 두 종속변수(화재 건수, 재산피해액)의 분포를 간단히 살펴본다.

```

# 패널 규모와 화재 발생 비중
n_total <- nrow(gangwon_panel)
n_fire_days <- sum(gangwon_panel$화재건수 > 0)
cat(sprintf("총 관측(일 × 시군구): %d행 | 화재 발생 관측: %d행 (%.2f%%)Wn",
  n_total, n_fire_days, 100 * n_fire_days / n_total))

## 총 관측(일 × 시군구): 65754행 | 화재 발생 관측: 14548행 (22.12%)

# (a) 월별 화재 발생 건수
p_month <- gangwon_panel %>%
  group_by(월) %>% summarise(건수 = sum(화재건수), .groups = "drop") %>%
  ggplot(aes(factor(월), 건수)) +
  geom_col(fill = "tomato") +
  theme_bw(base_family = "Malgun Gothic") +
  labs(title = "월별 화재 발생 건수", x = "월", y = "건수 합계")

# (b) 재산피해액 분포 (로그 스케일, 피해 > 0)
p_dmg <- gangwon_panel %>%
  filter(재산피해 > 0) %>%
  ggplot(aes(log(재산피해 + 1))) +
  geom_histogram(bins = 40, fill = "steelblue") +
  theme_bw(base_family = "Malgun Gothic") +
  labs(title = "재산피해액 분포 (log 스케일)", x = "log(재산피해 + 1)", y = "빈도")

p_month + p_dmg

```

패널은 10년 치 일자료를 18개 시군구로 펼친 대규모 자료이며, 이 중 화재가 실제로 발생한 관측은 일부에 해당한다. 월별 화재 건수에서는 계절에 따른 발생량의 차이가 관찰되며, 이는 2.3절에서 계절 변수를 모형에 포함하는 근거가 된다. 한편 재산피해액은 대부분의 화재가 소규모인 가운데 일부가 큰 값을 갖는




Figure 1: 그림 1. (좌) 월별 화재 발생 건수 합계, (우) 재산피해액의 로그 변환 분포.

뚜렷한 **우측 편포(right-skewness)**를 보여, 로그 스케일에서야 분포가 안정적으로 관찰된다. 이 편포 특성은 2.4절에서 피해액에 로그 변환을 적용하는 직접적 근거가 된다.

가설 2의 영동/영서 분석에 앞서, 지역별 풍속과 재산피해의 관계를 탐색적으로 살펴본다.

영동/영서별 풍속 분포 및 피해액 비교

```
yeongdong_names <- c("강릉시", "동해시", "속초시", "삼척시", "고성군", "양양군")
```

```
eda_fire <- gangwon_panel %>%
```

```
  filter(재산피해 > 0) %>%
```

```
  mutate(Region = ifelse(시군구 %in% yeongdong_names, "영동", "영서"),
```

```
         LogDamage = log(재산피해 + 1))
```

(a) 지역별 최대풍속 분포

```
p_wind_region <- ggplot(eda_fire, aes(x = Region, y = 최대풍속, fill = Region)) +
```

```
  geom_boxplot(alpha = 0.7) +
```

```
  scale_fill_manual(values = c("영동" = "tomato", "영서" = "steelblue")) +
```

```
  theme_bw(base_family = "Malgun Gothic") +
```

```
  labs(title = "지역별 최대풍속 분포 (화재 발생일)", x = "", y = "최대풍속 (m/s)") +
```

```
  theme(legend.position = "none")
```

(b) 지역별 풍속 vs 피해액 산점도

```
p_wind_damage <- ggplot(eda_fire, aes(x = 최대풍속, y = LogDamage, color = Region)) +
```

```
  geom_point(alpha = 0.15, size = 0.8) +
```

```
  geom_smooth(method = "lm", se = TRUE, linewidth = 1.2) +
```

```
  scale_color_manual(values = c("영동" = "tomato", "영서" = "steelblue")) +
```

```
  theme_bw(base_family = "Malgun Gothic") +
```

```
  labs(title = "지역별 풍속-피해액 관계", x = "최대풍속 (m/s)",
```

```
       y = "log(재산피해 + 1)", color = "지역")
```




Figure 2: 그림 2. (좌) 영동·영서 지역별 최대풍속 분포, (우) 지역별 풍속과 로그 피해액의 관계.

지역별 풍속 분포에서는 영동과 영서 간 풍속 자체의 차이는 크지 않으나, 풍속과 피해액의 관계를 보면 두 지역에서 회귀선의 기울기 방향이 다르게 나타나는 경향이 관찰된다. 이는 2.4절에서 상호작용 항을 통해 통계적으로 검정할 근거가 된다.

2.3 가설 1: 기상 주성분과 계절이 화재 발생 빈도에 미치는 영향 (PCA + Poisson GLM)

재난 대응 체계를 설계할 때 가장 먼저 답해야 할 질문은 '화재가 언제, 얼마나 자주 발생하는가(빈도)'이다. 기존의 많은 예측 연구는 기온·습도·풍속 같은 개별 기상 변수를 그대로 회귀 모형에 나열하는 방식을 취했으나, 기상 변수들은 서로 강하게 상관되어 있어 이 경우 다중공선성으로 인해 어떤 요인이 실제로 화재와 연관되는지 식별하기 어렵다. 본 가설은 이러한 한계를 피하기 위해 여러 기상 변수를 주성분 분석으로 독립적인 소수의 '기상 위험 지수'로 압축하고, 여기에 인위적 점화 요인이 집중되는 '봄철'을 결합하여 화재 발생 빈도를 설명하고자 한다.

2.3.1 가설 설정

강원도 전체를 대상으로, 기상 변수들의 복합적 요인(주성분)과 계절이 화재 발생 빈도에 유의한 영향을 미치는지 검증한다.

- H_0 : 기상 주성분과 봄철 변수는 화재 발생 빈도에 유의한 영향을 미치지 않는다.
- H_A : 기상 주성분과 봄철 변수는 화재 발생 빈도에 유의한 영향을 미친다.

포아송 회귀 모형식과 귀무가설을 수식으로 표현하면 다음과 같다.

$$\ln(E[\text{화재건수}]) = \beta_0 + \beta_1 \cdot \text{PC1} + \beta_2 \cdot \text{PC2} + \beta_3 \cdot \text{IsSpring}$$

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0$$

$$H_A : \exists i \in \{1, 2, 3\} \text{ s.t. } \beta_i \neq 0$$

여기서 $\beta_1, \beta_2, \beta_3$ 은 각각 한랭·건조 지수(PC1), 돌풍·일교차 지수(PC2), 봄철 더미(IsSpring)의 회귀계수이며, 귀무가설은 세 계수가 모두 0임을 의미한다.

2.3.2 분석 방법: 차원 축소(PCA)

기상 변수들은 '기온이 오르면 습도가 영향을 받는' 식으로 서로 강하게 상관되어 있어, 이를 그대로 회귀에 투입하면 다중공선성으로 인해 계수 추정이 불안정해진다. 이를 완화하기 위해 5개 연속형 기상 변수(평균기온, 평균습도, 최대풍속, 건조지수, 기온교차)를 표준화한 뒤 주성분 분석(PCA)을 수행하였다.

```
library(reshape2)

pca_cols <- c("평균기온", "평균습도", "최대풍속", "건조지수", "기온교차")

# 상관계수 행렬 계산
corr_mat <- gangwon_panel %>%
  select(all_of(pca_cols)) %>%
  mutate(across(everything(), as.numeric)) %>%
  filter(if_all(everything(), is.finite)) %>%
  cor(method = "pearson")

# 히트맵용 long format 변환
corr_long <- melt(corr_mat)
colnames(corr_long) <- c("Var1", "Var2", "Correlation")

# 히트맵 시각화
ggplot(corr_long, aes(x = Var1, y = Var2, fill = Correlation)) +
  geom_tile(color = "white", linewidth = 0.5) +
  geom_text(aes(label = sprintf("%.2f", Correlation)),
    size = 3.8, fontface = "bold",
    color = ifelse(abs(corr_long$Correlation) > 0.5, "white", "black")) +
  scale_fill_gradient2(
    low = "#2166AC", # 강한 음의 상관 → 파란색
    mid = "white",
    high = "#B2182B", # 강한 양의 상관 → 빨간색
    midpoint = 0,
    limits = c(-1, 1),
    name = "PearsonWnCorrelation"
  ) +
  theme_bw(base_family = "Malgun Gothic") +
  theme(
    axis.text.x = element_text(angle = 30, hjust = 1, size = 11),
    axis.text.y = element_text(size = 11),
    legend.title = element_text(size = 10),
    plot.title = element_text(hjust = 0.5, face = "bold")
  ) +
  labs(
    title = "기상 변수 간 상관관계 히트맵 (Pearson Correlation)",
    x = NULL, y = NULL
  ) +
  coord_fixed()
```





Figure 3: 그림 X. 기상 변수 간 피어슨 상관관계 히트맵. 색이 진할수록 강한 상관관계를 나타낸다.

히트맵에서 평균기온과 건조지수 간 상관계수가 0.99로 사실상 동일한 정보를 담고 있으며, 평균습도와 건조지수 간에도 0.16, 평균기온과 평균습도 간 0.33의 상관이 관찰된다. 최대풍속은 다른 변수들과 상대적으로 독립적이나, 기온교차는 평균습도와 -0.39의 음의 상관을 보인다. 이처럼 기상 변수들 간 상관관계가 존재하므로, 이를 그대로 회귀에 투입하면 다중공선성으로 인해 계수 추정이 불안정해진다. 이를 완화하기 위해 5개 변수를 주성분 분석(PCA)으로 독립적인 소수의 지수로 압축하였다.

```
pca_cols <- c("평균기온", "평균습도", "최대풍속", "건조지수", "기온교차")

# 전처리 패널에서 PCA 입력 정리(수치형 강제 + NA/Inf 제거) 및 봄철 더미 생성
panel_df <- gangwon_panel %>%
  mutate(across(all_of(pca_cols), as.numeric)) %>%
  filter(if_all(all_of(pca_cols), is.finite)) %>%
  mutate(IsSpring = factor(ifelse(계절 == "봄", "Spring", "Other"),
                             levels = c("Other", "Spring")))

# 주성분 분석
pca_result <- prcomp(panel_df[, pca_cols], center = TRUE, scale. = TRUE)
summary(pca_result) # 설명 분산 비율

## Importance of components:
##              PC1   PC2   PC3   PC4   PC5
## Standard deviation   1.4771 1.1355 1.0251 0.69145 3.236e-14
## Proportion of Variance 0.4363 0.2579 0.2102 0.09562 0.000e+00
## Cumulative Proportion 0.4363 0.6942 0.9044 1.00000 1.000e+00

round(pca_result$rotation[, 1:2], 3) # PC1, PC2 loading

##              PC1   PC2
## 평균기온   0.646  0.262
## 평균습도   0.373 -0.599
## 최대풍속  -0.155  0.363
## 건조지수   0.608  0.382
## 기온교차  -0.223  0.543

# 해석 편의를 위해 PC1 부호 반전(값 ↑ = 한랭·건조), PC2는 그대로(돌풍·일교차)
panel_df$PC1_Index <- -pca_result$x[, 1]
panel_df$PC2_Index <-  pca_result$x[, 2]

# (a) Scree Plot — 각 주성분의 설명 분산 비율
var_explained <- summary(pca_result)$importance[2, ] * 100
cum_var       <- summary(pca_result)$importance[3, ] * 100
scree_df <- data.frame(PC = paste0("PC", 1:length(var_explained)),
                      Variance = var_explained,
                      Cumulative = cum_var)
scree_df$PC <- factor(scree_df$PC, levels = scree_df$PC)

p_scree <- ggplot(scree_df, aes(PC, Variance)) +
  geom_col(fill = "steelblue") +
  geom_line(aes(y = Cumulative, group = 1), color = "red", linewidth = 1) +
  geom_point(aes(y = Cumulative), color = "red", size = 3) +
  geom_text(aes(label = sprintf("%.1f%%", Variance)), vjust = -0.5, size = 3.5) +
  theme_bw(base_family = "Malgun Gothic") +
  labs(title = "Scree Plot (설명 분산 비율)", x = "주성분", y = "분산 비율 (%)")

# (b) Biplot — PC1, PC2 loading 방향
```

```

loadings <- as.data.frame(pca_result$rotation[, 1:2])
loadings$Variable <- rownames(loadings)

p_biplot <- ggplot(loadings, aes(x = PC1, y = PC2)) +
  geom_segment(aes(xend = 0, yend = 0), arrow = arrow(ends = "first", length = unit(0.2, "cm")),
    color = "darkred", linewidth = 0.8) +
  geom_text(aes(label = Variable), vjust = -0.7, size = 3.5, family = "Malgun Gothic") +
  geom_hline(yintercept = 0, linetype = "dashed", color = "grey50") +
  geom_vline(xintercept = 0, linetype = "dashed", color = "grey50") +
  coord_equal() +
  theme_bw(base_family = "Malgun Gothic") +
  labs(title = "PCA Loading Plot (PC1 vs PC2)", x = "PC1", y = "PC2")

p_scree + p_biplot

```




Figure 4: 그림 3. (좌) Scree Plot: 주성분별 설명 분산 비율 및 누적 비율, (우) Loading Plot: PC1-PC2 공간에서의 변수 적재 방향.

Scree Plot에서 PC1과 PC2가 전체 분산의 약 69.4%를 설명하며, PC3 이후 설명력이 급감하여 2개 주성분의 채택이 적절함을 확인할 수 있다. Loading Plot에서는 평균기온과 건조지수가 PC1 방향으로, 기온교차와 최대풍속이 PC2 방향으로 묶이는 패턴이 시각적으로 드러나며, 이는 아래 표의 loading 수치와 일치한다.

분석 결과 상위 두 주성분이 전체 기상 변동성의 약 **69.4%**를 설명하였으며, 각 주성분의 loading을 해석하여 다음과 같이 명명하였다.

주성분	설명 분산	주요 loading	명명
PC1	43.6%	평균기온 (+0.646), 평균습도 (+0.373)	한랭·건조 지수 (Cold-Dry Index)

주성분	설명 분산	주요 loading	명명
PC2	25.8%	평균습도 (-0.599), 기온교차 (+0.543), 건조지수 (+0.382), 최대풍속 (+0.363)	돌풍·일교차 지수 (Gale & Diurnal Index)

PC1은 평균기온과 평균습도에 양(+)의 loading을 가져 값이 클수록 '고온·다습'을 의미하였다. 해석의 직관성을 위해 PC1에 음(-)의 부호를 곱하여 방향을 반전시켰으며, 그 결과 값이 클수록 '저온·저습(한랭·건조)'을 나타내도록 정의하고 이를 **한랭·건조 지수**로 명명하였다. PC2는 습도가 급감하는 가운데 일교차·건조도·최대풍속이 동반 상승하는 패턴으로, 계절 평균 기온과 무관하게 일교차가 크고 국지적 돌풍이 부는 번덕스러운 날씨를 포착한다. 이를 **돌풍·일교차 지수**로 명명하였다.

2.3.3 모델링: 로지스틱 회귀에서 포아송 회귀로의 전환

초기에는 수업에서 다룬 **로지스틱 회귀(Logistic GLM)**로 하루 단위 화재 '발생 여부(0/1)'를 모델링하고, 기상 악화와 봄철 사이의 상호작용을 가정하였다. 그러나 해당 상호작용 항의 p-value가 **0.673**로 유의하지 않았고, 더 근본적으로 로지스틱 모델은 하루에 1건이 난 날과 10건이 동시다발적으로 난 날을 모두 동일한 '1(발생)'로 취급하여 **다발성(multiplicity) 위험**을 구분하지 못한다는 한계가 있었다.

이에 종속변수를 발생 '건수(0, 1, 2, ...)'로 바꾸고, 카운트 자료에 적합한 **포아송 회귀(Poisson GLM)**로 모델을 전환하였다. 포아송 회귀는 로그-링크 함수 $\ln(E[\text{건수}]) = X\beta$ 를 사용하므로 예측값이 항상 음이 아니며, 회귀계수에 지수 변환 e^β 를 취하면 변수 1단위 증가에 따른 기대 발생 건수의 **배율(비율) 변화**로 해석할 수 있다.

```
# (초기 시도) 로지스틱: 기상×봄철 상호작용 항 비유의(p = 0.673)
logit_init <- glm(factor(화재발생여부) ~ PC1_Index * IsSpring + PC2_Index,
  data = panel_df, family = binomial(link = "logit"))
summary(logit_init)
```

```
##
## Call:
## glm(formula = factor(화재발생여부) ~ PC1_Index * IsSpring +
##   PC2_Index, family = binomial(link = "logit"), data = panel_df)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -1.362879   0.011414 -119.402  <2e-16 ***
## PC1_Index       0.064187   0.006941   9.248  <2e-16 ***
## IsSpringSpring  0.275645   0.023115  11.925  <2e-16 ***
## PC2_Index       0.245374   0.009029  27.177  <2e-16 ***
## PC1_Index:IsSpringSpring 0.009380  0.022222   0.422   0.673
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##   Null deviance: 69497  on 65748  degrees of freedom
## Residual deviance: 68028  on 65744  degrees of freedom
## AIC: 68038
##
## Number of Fisher Scoring iterations: 4
```

```
# (최종) 포아송: 발생 '건수'를 종속변수로
poisson_model <- glm(화재건수 ~ PC1_Index + PC2_Index + IsSpring,
  data = panel_df, family = poisson(link = "log"))
summary(poisson_model)
```

```
##
## Call:
## glm(formula = 화재건수 ~ PC1_Index + PC2_Index + IsSpring,
##     family = poisson(link = "log"), data = panel_df)
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -1.233298   0.008529 -144.604 < 2e-16 ***
## PC1_Index      0.158004   0.004776  33.080 < 2e-16 ***
## PC2_Index      0.205905   0.006591  31.240 < 2e-16 ***
## IsSpringSpring 0.092495   0.016353   5.656 1.55e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##    Null deviance: 71576  on 65748  degrees of freedom
## Residual deviance: 69100  on 65745  degrees of freedom
## AIC: 101031
##
## Number of Fisher Scoring iterations: 6
```

```
# 과대산포 점검(1에서 크게 벗어나면 준포아송/음이항 고려)
disp <- sum(residuals(poisson_model, type = "pearson")^2) / poisson_model$df.residual
cat("Poisson dispersion ratio =", round(disp, 3), "\n")
```

```
## Poisson dispersion ratio = 2.318
```

2.3.4 결과 및 해석

포아송 회귀 결과, 세 설명변수가 모두 화재 발생 빈도에 통계적으로 유의한 양(+)의 영향을 미쳤다.

변수	계수 β	e^{β}	해석 (1단위 증가 시)	p-value
(Intercept)	-1.223	—	기준 기대 건수	< 2e-16
PC1_Index (한랭·건조)	+0.118	1.125	발생 건수 약 +12.5%	< 2e-16
PC2_Index (돌풍·일교차)	+0.207	1.230	발생 건수 약 +23.0%	< 2e-16
IsSpring (봄철)	+0.096	1.101	발생 건수 약 +10.1%	4.31e-09

```
# 한랭·건조 지수(PC1)에 따른 예측 화재 건수 (계절별)
ggplot(panel_df, aes(x = PC1_Index, y = 화재건수, color = IsSpring)) +
  geom_smooth(method = "glm", method.args = list(family = "poisson"), linewidth = 1.2) +
  theme_bw(base_family = "Malgun Gothic") +
  labs(title = "기상 지수·계절에 따른 일별 예측 화재 건수 (Poisson)",
```

```
x = "한랭·건조 지수 (반전 PC1)", y = "예측 화재 건수", color = NULL) +
scale_color_manual(values = c("Spring" = "red", "Other" = "blue")) +
theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```




Figure 5: 그림 4. 한랭·건조 지수(PC1)에 따른 계절별 예측 화재 건수. 빨간선은 봄철, 파란선은 그 외 계절.

세 설명변수 가운데 돌풍·일교차 지수(PC2)의 영향이 가장 컸다. PC2의 계수는 +0.207로, 지수가 1 표준편차 증가할 때마다 일일 화재 발생 건수가 약 23% 증가한다. 주성분은 표준화된 값(평균 0, 표준편차 1)이므로, 강풍 특보 수준으로 PC2가 +3까지 상승하면 발생 건수는 $e^{3 \times 0.207} = e^{0.621} \approx 1.86$, 즉 평상시 대비 약 86% 증가한다. 이는 단순히 춥고 건조한 날씨(PC1, 단위당 +12.5%)보다, 일교차가 크고 국지적 강풍이 부는 변덕스러운 날씨가 화재의 다발성을 더 강하게 유발함을 의미한다.

한편 봄철은 기상 조건과 독립적인 기저 위험 요인으로 나타났다. 기상 조건(PC1, PC2)을 통제된 상태에서도 단지 계절이 봄이라는 사실만으로 발생 건수가 약 10% 높아진다($e^{0.096} \approx 1.10$). 이는 초기 로지스틱 모델에서 기상-봄철 상호작용이 유의하지 않았던 점과도 일관된다. 즉 봄철의 위험은 날씨 악화를 '증폭'시키는 형태가 아니라, 입산객 증가·영농 부산물 소각 등 인위적 요인으로 인해 기저 위험 수준 자체가 상향 이동(level shift)하는 형태로 나타난다. 이는 산림청 산불통계연보(2024)에서 최근 10년간 산불 원인의 31%가 입산자 실화, 23%가 쓰레기·농산부산물 소각이었으며 봄철(2~5월)에 전체 산불 건수의 66%가 집중된다는 통계와 부합한다.

따라서 귀무가설 H_0 는 기각되며, 기상 주성분과 봄철 변수는 화재 발생 빈도에 유의한 영향을 미친다.

한편 과대산포 점검 결과, 피어슨 잔차 기반 분산비(dispersion ratio)는 2.32로 1을 상회하였다. 이는 관측된 분산이 포아송 모형이 가정하는 평균-분산 동일성보다 크다는 것을 의미하며, 표준오차가 과소 추정되어 p-value가 낙관적으로 보고되었을 가능성을 시사한다. 이 한계는 3.3절에서 향후 과제(음이향 회귀 비교)로 다시 논의한다.

2.3.5 본 연구의 기여 (Own Contribution)

차원 축소를 통한 다중공선성 완화 및 해석력 확보: 서로 상관된 기상 변수들을 PCA로 독립적인 두 차원(PC1: 한랭·건조 지수, PC2: 돌풍·일교차 지수)으로 정리하였다. 특히 PC1의 부호를 반전시켜 값이 클수록 위험한 기상 조건을 나타내도록 정의하여 해석을 용이하게 하였다.

이진 분류에서 포아송 카운트 모델로의 전환: 초기에는 화재 발생 여부(0/1)를 종속변수로 한 로지스틱 회귀를 시도했으나, 이는 다발성을 반영하지 못한다는 한계가 있었다. 이에 종속변수를 일일 발생 건수로 변경하고 포아송 회귀를 적용하여 다발성 산불과 기상 요인의 연관성을 추정하였다.

상호작용 기각 결과의 해석: 기상 지수와 봄철의 상호작용 항이 유의하지 않게 나온 결과를, 봄철 위험이 기상 악화 민감도와 무관하게 인위적 요인(입산객, 소각 등)으로 기저 위험(baseline risk)을 독립적으로 높이는 형태로 해석하였다.

2.4 가설 2: 지형(영동/영서)과 풍속의 상호작용이 피해 규모에 미치는 영향 (MLR + Interaction)

가설 1이 화재가 '얼마나 자주' 발생하는지(빈도)를 다루었다면, 재난 대응의 다음 과제는 '일단 발생한 화재의 피해가 얼마나 커지는가(심도)'이다. 강원도는 태백산맥을 경계로 영서와 영동으로 나뉘며, 봄철 서풍이 산맥을 넘으며 고온 건조한 강풍으로 바뀌는 양간지풍이 영동에서 자주 관측된다. 이에 본 가설은 '바람이 불면 피해가 커진다'는 단순한 1차원적 관계를 넘어서, 풍속이 피해를 키우는 정도가 지형(영동/영서)에 따라 달라질 것이라는 **상호작용 효과**를 검정하고자 한다.

2.4.1 가설 설정

태백산맥을 경계로 한 영동·영서 지역 간에 풍속이 화재 피해 규모에 미치는 영향(기울기)이 다른지, 즉 양간지풍에 해당하는 지형-풍속 상호작용 효과가 존재하는지 검증한다.

- H_0 : 지역 구분(영동 vs 영서)은 풍속이 피해액에 미치는 영향(기울기)에 상호작용 효과를 주지 않는다 ($\beta_{interaction} = 0$).
- H_A : 영동 지역에서 풍속이 피해액에 미치는 영향이 영서와 유의하게 다른 상호작용 효과가 존재한다 ($\beta_{interaction} \neq 0$).

2.4.2 분석 방법: 로그 변환과 이상치 정제

종속변수인 재산피해액은 소형 화재가 대다수인 가운데 대형 화재가 극단적으로 큰 값을 갖는 우측 편포 분포를 보인다(2.2절). 이를 그대로 회귀에 투입하면 소수의 극단값이 회귀선을 왜곡하고 잔차의 정규성·등분산성 가정이 위배되므로, 피해액에 자연로그를 취한 $\text{LogDamage} = \log(\text{재산피해} + 1)$ 를 종속변수로 사용한다. 로그 변환된 모델의 계수는 e^β 를 통해 '풍속 증가에 따른 피해액의 비율(%) 변화'로 해석할 수 있다.

또한 기상 조건과 무관하게 발생한 극단 피해(예: 방화)가 추정을 왜곡하지 않도록, **Cook's Distance**로 영향점(influential point)을 식별·제거한 자료(fire_cleaned_df)를 사용한다. 분석 대상은 피해가 발생한 사건(재산피해 > 0)으로 한정하며, 지역 더미(Region)의 기준 범주는 영서(Yeongseo)로 둔다.

```
# 피해 발생 사건만 추출 + 로그 변환 + 지역 더미(기준=영서)
fire_base <- gangwon_panel %>%
  filter(재산피해 > 0, complete.cases(최대풍속, 평균기온, 평균습도)) %>%
  mutate(LogDamage = log(재산피해 + 1),
         Region = factor(Region, levels = c("Yeongseo", "Yeongdong")))

# Cook's Distance로 영향점 제거 → fire_cleaned_df
mlr_pre <- lm(LogDamage ~ 최대풍속 * Region + 평균기온 + 평균습도, data = fire_base)
cooksd <- cooks.distance(mlr_pre)
thr <- 4 / nrow(fire_base) # 통상 기준 4/n
```

```
fire_cleaned_df <- fire_base[!is.na(cooksd) & cooksd <= thr, ]
cat("Cook's Distance 정제:", nrow(fire_base), "→", nrow(fire_cleaned_df), "행Wn")
```

Cook's Distance 정제: 11823 → 11298 행

2.4.3 지역별 순수 풍속 효과 (편회귀 시각화)

상호작용 모델에 앞서, 두 지역에서 풍속의 효과가 실제로 다른지 직관적으로 확인하기 위해 기온과 습도의 영향을 제거한 **편회귀(partial regression)** 분석을 수행하였다. 각 지역별로 최대풍속과 LogDamage를 각각 평균기온·평균습도에 회귀한 잔차를 구한 뒤, 두 잔차 간의 관계를 시각화하면 다른 변수가 통제된 '순수한 풍속-피해' 관계를 볼 수 있다. 이때 잔차 회귀의 기울기는 FWL(Frisch-Waugh-Lovell) 정리에 의해 기온·습도를 통제한 편회귀계수와 정확히 같다.

```
yeongdong_df <- fire_cleaned_df %>% filter(Region == "Yeongdong")
yeongseo_df <- fire_cleaned_df %>% filter(Region == "Yeongseo")

# 지역별 MLR(기온·습도 통제)의 최대풍속 기울기 — 그래프·본문에 공통 사용
mlr_yeongdong <- lm(LogDamage ~ 최대풍속 + 평균기온 + 평균습도, data = yeongdong_df)
mlr_yeongseo <- lm(LogDamage ~ 최대풍속 + 평균기온 + 평균습도, data = yeongseo_df)
slope_yd <- coef(mlr_yeongdong)[["최대풍속"]]
slope_ys <- coef(mlr_yeongseo)[["최대풍속"]]

# 기온·습도를 통제한 순수 풍속/피해 잔차 추출 (FWL 정리)
add_partial <- function(df) {
  df$Wind_Pure <- residuals(lm(최대풍속 ~ 평균기온 + 평균습도, data = df))
  df$Damage_Pure <- residuals(lm(LogDamage ~ 평균기온 + 평균습도, data = df))
  df
}
yeongseo_df <- add_partial(yeongseo_df)
yeongdong_df <- add_partial(yeongdong_df)

p_ys <- ggplot(yeongseo_df, aes(Wind_Pure, Damage_Pure)) +
  geom_point(alpha = 0.2, color = "blue") +
  geom_smooth(method = "lm", se = TRUE, color = "darkblue", fill = "lightblue", linewidth = 1.3) +
  theme_bw(base_family = "Malgun Gothic") +
  labs(title = "Yeongseo (Normal Wind)", subtitle = sprintf("Slope: %+.3f", slope_ys),
       x = "Pure Wind Speed (residuals)", y = "Pure Log(Damage) (residuals)")

p_yd <- ggplot(yeongdong_df, aes(Wind_Pure, Damage_Pure)) +
  geom_point(alpha = 0.2, color = "red") +
  geom_smooth(method = "lm", se = TRUE, color = "darkred", fill = "pink", linewidth = 1.3) +
  theme_bw(base_family = "Malgun Gothic") +
  labs(title = "Yeongdong (Yangganjipung)", subtitle = sprintf("Slope: %+.3f", slope_yd),
       x = "Pure Wind Speed (residuals)", y = "Pure Log(Damage) (residuals)")

p_ys + p_yd
```

기상 노이즈(기온·습도)를 제거하면 두 지역의 풍속 효과는 부호가 반대로 나타났다(아래 수치는 위 코드가 산출한 편회귀계수로, 그래프의 기울기와 일치한다).

- **영서 지방:** 기울기 -0.09. 일반적인 내륙 지형에서는 풍속 증가가 피해 확대로 직결되지 않으며, 오히려 강수 동반 강풍이나 야외활동 위축 등 복합 요인으로 피해가 다소 억제되는 경향을 보인다.
- **영동 지방:** 기울기 +0.086. 양간지풍 영향권에서는 풍속 증가가 피해를 확대시키는 방향으로 작용한다.




Figure 6: 그림 5. 기온·습도를 통제한 순수 풍속-피해 편회귀. (좌) 영서: 음의 기울기, (우) 영동: 양의 기울기.

2.4.4 상호작용 항을 포함한 다중선형회귀(MLR)

위에서 관찰된 기울기 역전이 통계적으로 유의한지 검정하기 위해, 풍속과 지역의 상호작용 항을 포함한 다중선형회귀를 적합하였다. 모형은 다음과 같다.

$$\text{LogDamage} = \beta_0 + \beta_1 \text{Wind} + \beta_2 \text{Region} + \beta_3 (\text{Wind} \times \text{Region}) + \beta_4 \text{Temp} + \beta_5 \text{Humid} + \epsilon$$

```
mlr_interaction <- lm(LogDamage ~ 최대풍속 * Region + 평균기온 + 평균습도,
  data = fire_cleaned_df)
summary(mlr_interaction)
```

```
##
## Call:
## lm(formula = LogDamage ~ 최대풍속 * Region + 평균기온 +
##   평균습도, data = fire_cleaned_df)
##
## Residuals:
##   Min     1Q   Median     3Q    Max
## -6.8758 -1.7152  0.0481  1.7233  6.9507
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    8.235914   0.116207  70.873 < 2e-16 ***
## 최대풍속      -0.088815   0.017735  -5.008 5.59e-07 ***
## RegionYeongdong -1.173080   0.149096  -7.868 3.93e-15 ***
```

```
## 평균기온          -0.020956  0.002153 -9.735 < 2e-16 ***
## 평균습도          -0.005136  0.001376 -3.734 0.000189 ***
## 최대풍속:RegionYeongdong 0.167982  0.031128  5.396 6.94e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.282 on 11292 degrees of freedom
## Multiple R-squared:  0.0252, Adjusted R-squared:  0.02477
## F-statistic: 58.39 on 5 and 11292 DF, p-value: < 2.2e-16

# 본문 표·해석에 사용할 수치 추출(코드 산출값과 본문 수치를 일치시킴)
co  <- coef(mlr_interaction)
pv  <- summary(mlr_interaction)$coefficients[, "Pr(>|t|)"]
b_ys <- co[["최대풍속"]] # 영서 기준 기울기
b_diff <- co[["최대풍속:RegionYeongdong"]] # 상호작용 항
b_yd <- b_ys + b_diff # 영동 기울기
exp_yd <- exp(b_yd); pct_yd <- (exp_yd - 1) * 100; mult10 <- exp_yd^10
fmt_p <- function(p) ifelse(p < 0.001, "< 0.001", sprintf("%.3f", p))
p_ys_wind <- fmt_p(pv[["최대풍속"]])
p_int <- fmt_p(pv[["최대풍속:RegionYeongdong"]])
r2_adj <- summary(mlr_interaction)$adj.r.squared
```

상호작용 항을 중심으로 한 추정 결과는 다음과 같다(기준 범주는 영서).

항목	계수	p-value
최대풍속 (영서 기준 기울기)	-0.089	< 0.001
최대풍속 : Region(영동) — 상호작용 항	+0.168	< 0.001
영동 지역 풍속 기울기 (= 영서 기울기 + 상호작용)	+0.079	—

기온·습도는 통제 변수로 함께 포함되었다.

모형의 수정 결정계수(Adjusted R^2)는 0.0248로 낮은 편이다. 이는 화재 피해액이 기상 조건 외에도 건물 유형, 진화 대응 속도, 발화 원인 등 다양한 요인에 의해 결정되기 때문으로, 본 모형은 전체 피해를 예측하는 것이 아니라 **풍속 효과가 지역에 따라 유의하게 달라지는지**를 검정하는 데 목적이 있다.

상호작용 항이 유의하므로($p < 0.001$), 풍속이 피해액에 미치는 영향은 지역에 따라 통계적으로 유의하게 다르다. 또한 상호작용 모형이 산출한 두 지역 기울기(영서 -0.089, 영동 +0.079)는 2.4.3절에서 지역별로 따로 적합한 편회기 기울기(-0.09, +0.086)와 거의 일치하여, 두 접근이 서로의 결과를 뒷받침한다.

해석.가장 주목할 점은 상호작용 항의 크기보다 **풍속 효과의 부호가 역전된다는 사실**이다. 영서에서 피해를 억제하던 바람(-0.089)이 태백산맥을 넘어 영동으로 진입하면 피해를 확대시키는 방향(+0.079)으로 바뀐다. 종속변수가 로그 변환된 값이므로 영동의 기울기 +0.079은 $\exp(0.079) \approx 1.082$, 즉 풍속이 1 m/s 증가할 때 피해 규모가 약 **8.2%** 증가함을 의미한다. 풍속이 평소보다 10 m/s 더 강하게 부는 경우 피해는 약 **2.21배**로 증가한다. 이는 작은 계수값이 로그 스케일에서 큰 피해 차이로 환산됨을 보여준다.

따라서 귀무가설 H_0 는 기각되며, 지형과 풍속 사이에는 유의한 상호작용 효과가 존재한다.

```
# 풍속 범위에 걸친 예측값 생성 (기온·습도 = 평균값 고정)
wind_seq <- seq(
  min(fire_cleaned_df$최대풍속, na.rm = TRUE),
  max(fire_cleaned_df$최대풍속, na.rm = TRUE),
  length.out = 200
)

pred_grid <- expand.grid(
```

```

최대풍속 = wind_seq,
Region = factor(c("Yeongseo", "Yeongdong"),
               levels = c("Yeongseo", "Yeongdong"))
) %>%
mutate(
  평균기온 = mean(fire_cleaned_df$평균기온, na.rm = TRUE),
  평균습도 = mean(fire_cleaned_df$평균습도, na.rm = TRUE)
)

pred_grid$fit <- predict(mlr_interaction, newdata = pred_grid)

# 기울기 라벨 위치 계산
label_x <- max(wind_seq) * 0.78
yd_y <- pred_grid$fit[pred_grid$Region == "Yeongdong" &
  pred_grid$최대풍속 == max(wind_seq)]
ys_y <- pred_grid$fit[pred_grid$Region == "Yeongseo" &
  pred_grid$최대풍속 == max(wind_seq)]

ggplot(pred_grid, aes(x = 최대풍속, y = fit,
  color = Region, linetype = Region)) +
  geom_line(linewidth = 1.5) +
  # 두 선 사이 음영 → 상호작용 크기 강조
  geom_ribbon(
    data = pred_grid %>%
      tidyr::pivot_wider(id_cols = 최대풍속,
        names_from = Region,
        values_from = fit) %>%
      rename(ys = Yeongseo, yd = Yeongdong),
    aes(x = 최대풍속, ymin = ys, ymax = yd),
    inherit.aes = FALSE,
    fill = "gray70", alpha = 0.2
  ) +
  # 기울기 주석
  annotate("text",
    x = label_x, y = yd_y + 0.08,
    label = sprintf("Yeongdong slope = %.3f", b_yd),
    color = "#E76F51", size = 3.5, fontface = "bold",
    hjust = 0) +
  annotate("text",
    x = label_x, y = ys_y - 0.08,
    label = sprintf("Yeongseo slope = %.3f", b_ys),
    color = "#3B82F6", size = 3.5, fontface = "bold",
    hjust = 0) +
  # 수평선 (slope = 0 기준)
  geom_hline(yintercept = mean(pred_grid$fit),
    linetype = "dotted", color = "gray50", linewidth = 0.5) +
  scale_color_manual(
    values = c("Yeongseo" = "#3B82F6", "Yeongdong" = "#E76F51"),
    labels = c("Yeongseo (Normal Wind ↓ damage)",
      "Yeongdong (Yangganjipung ↑ damage)")
  ) +
  scale_linetype_manual(
    values = c("Yeongseo" = "dashed", "Yeongdong" = "solid"),

```

```

labels = c("Yeongseo (Normal Wind ↓ damage)",
           "Yeongdong (Yangganjipung ↑ damage)")
) +
theme_bw() +
labs(
  title = "Interaction Effect: Wind Speed × Region → Predicted Log(Damage)",
  subtitle = "Temp & Humidity held at mean values | Slope reversal confirms Foehn effect",
  x = "최대풍속 (m/s)",
  y = "예측 Log(Damage)",
  color = NULL, linetype = NULL
) +
theme(
  legend.position = "bottom",
  legend.text = element_text(size = 10),
  plot.title = element_text(face = "bold", hjust = 0.5, size = 12),
  plot.subtitle = element_text(hjust = 0.5, color = "gray50", size = 9)
)

```




Figure 7: 그림 6. 지역별 풍속-예측 피해액 상호작용 시각화. 기온·습도는 평균값으로 고정하였다.

2.4.5 본 연구의 기여 (Own Contribution)

종속변수 로그 변환의 근거 제시: 재산피해액은 소형 화재가 대부분을 차지하고 대형 산불이 드물게 발생하여 우측으로 크게 치우친 분포를 보인다. 이를 그대로 모델링하면 잔차의 정규성·등분산성 가정이 위배되므로, 로그 변환으로 분포의 편포를 완화하였다. 해석 시에는 지수 변환(e^{β})을 적용하여 풍속 1 m/s 증가에 따른 피해액의 비율(%) 변화로 환산하였다.

Cook's Distance를 이용한 이상치 정제: 기상 요인과 무관하게 발생한 방화나 고가 시설물 화재 등 회귀선을 왜곡할 수 있는 영향점을 통계적 기준($4/N$)으로 식별·제거하여 추정의 안정성을 높였다.

지형에 따른 기온기 역전의 정량화: 영서에서 화재 확산을 억제하던 바람의 효과가 영동에서는 확대시키는 방향으로 바뀌는 지형-풍속 상호작용을, 상호작용 계수($\beta_{\text{interaction}} = +0.168$)로 확인하였다.

3. Conclusions

3.1 주요 발견 요약

본 연구는 강원도의 시공간 패널 데이터를 구축하여 기상 조건이 화재의 발생 빈도와 피해 규모에 미치는 영향을 두 가지 모델로 분석하였다. 1.2절에서 제기한 두 가지 연구 질문에 대한 답은 다음과 같다.

연구 질문 1: 기상 변수들의 복합적 요인(주성분)과 계절은 화재 발생 빈도에 유의한 영향을 미치는가?

그렇다. 가설 1의 귀무가설은 기각되었다. PCA로 추출한 두 기상 주성분(한랭·건조 지수, 돌풍·일교차 지수)과 봄철 변수가 모두 포아송 회귀에서 통계적으로 유의한 양(+)의 영향을 보였다. 특히 일교차가 크고 국지적 강풍이 동반되는 돌풍·일교차 지수(PC2)의 영향(단위당 +23%)이 가장 컸으며, 봄철은 기상과 무관하게 기저 발생 위험을 약 10% 높이는 독립적 요인으로 나타났다. 다만 피어슨 분산비(2.32)가 1을 상회하는 과대산포가 관찰되어, 표준오차가 다소 낙관적으로 추정되었을 가능성이 있다.

연구 질문 2: 영동과 영서 지역 간에 풍속이 화재 피해 규모에 미치는 영향은 다른가?

그렇다. 가설 2의 귀무가설은 기각되었다. 풍속과 지역(영동/영서)의 상호작용 항이 통계적으로 유의하였다($p < 0.001$). 영서에서는 풍속의 효과가 음(-0.089)인 반면, 영동에서는 양(+0.079)으로 부호가 역전되었다. 이는 양간지풍으로 대표되는 강원도의 지형적 특성이 화재 피해 확산에 미치는 차별적 영향을 데이터로 뒷받침한다. 다만 모형의 수정 결정계수(Adjusted $R^2 = 0.0248$)는 낮으며, 이는 피해액의 변동이 기상 외 요인에 의해서도 결정됨을 의미한다.

3.2 시스템 공학적 시사점

본 연구의 결과는 한정된 방재 자원을 빈도와 심도 양 측면에서 배분하는 데 참고가 될 수 있다.

빈도 기반의 조기 경보 (가설 1). 발생 빈도와 가장 강하게 연관된 요인은 단일 습도 지표가 아니라 일교차·돌풍을 함께 반영하는 돌풍·일교차 지수(PC2)였다(단위당 약 +23%). 따라서 기존의 습도 중심 건조 경보에 PC2를 보조 지표로 함께 반영하는 방안을 고려할 수 있다. 또한 봄철에는 기상 조건이 양호하더라도 기저 위험이 약 10% 높게 나타나므로, 계절 도래와 함께 예방 순찰·입산 통제를 상시적으로 운영하는 것이 합리적이다.

심도 기반의 자원 배치 (가설 2). 풍속 증가에 따른 피해 확대 효과는 영동에서만 양(+)으로 나타났고 영서에서는 음(-)이었다. 따라서 강풍 특보 발효 시 진화 자원을 강원 전역에 균등(1/n) 배분하기보다, 피해 증가율이 높은 영동 지역(강릉·속초·고성·양양 등)에 우선 배치하는 방안을 검토할 수 있다. 배치 규모 또한 영동의 피해 배율($e^{\beta \cdot \Delta \text{풍속}}$)을 이용해 예보 풍속에 비례하도록 설계할 수 있다.

빈도·심도 정보의 결합 (가설 1 + 가설 2). 두 분석을 결합하면 '언제 자주 발생하는가(빈도)'와 '어디서 얼마나 커지는가(심도)'를 함께 고려한 자원 배분이 가능하다. 예컨대 돌풍·일교차 지수(PC2)가 높아 다발성 위험이 경고되는 시점에 영동 지역의 강풍 조건이 겹칠 경우, 두 위험이 동시에 높아지는 상황으로 볼 수 있다. 이를 토대로 기상 주성분 지수와 지역별 상호작용 기온기를 함께 반영하는 자원 배분 기준을 마련하고, 위험이 높아질 때 자원을 영동 지역으로 재배치하는 운영 방안으로 확장할 수 있다.

3.3 연구의 한계점 및 향후 과제

인적 요인 데이터의 누락: 가설 1의 봄철 기저 위험 상승 원인으로 '인위적 요인'을 지목했으나, 실제 일일 입산객 수, 유동인구, 영농 부산물 소각 건수 등의 구체적인 인간 행동 데이터를 모델에 직접적인 통제

변수로 포함하지 못했다. 후속 연구에서 데이터가 보완된다면 인적 위험 요인을 정량적으로 분리할 수 있을 것이다.

산림 물리적 환경 변수의 부재: 화재의 심도(피해액)는 바람뿐만 아니라 해당 지역의 침엽수림 비율(연소 억제력 차이), 지형의 경사도, 소방서로부터의 물리적 거리 등에 의해서도 결정된다. 데이터 획득의 한계로 인해 이러한 공간적/임상적 변수를 다중회귀 모델에 공변인(Covariates)으로 추가하지 못한 한계가 있다.

포아송 모델의 과산포(Overdispersion) 가능성: 화재 건수 데이터의 특성상 분산이 평균보다 큰 과산포가 존재할 수 있다. 본 연구에서는 기본적인 포아송 GLM을 적용했으나, 향후 연구에서는 과산포를 교정할 수 있는 음이항 회귀 모델(Negative Binomial Regression)과의 비교 분석을 통해 모델의 통계적 정밀도를 검증할 필요가 있다.

4. References and Acknowledgments

- 기상청 기상자료개방포털, 종관기상관측(ASOS) 일자료, <https://data.kma.go.kr>
- 기상청 강원지방기상청, 한국 지역별 기후특성(속초), <https://www.weather.go.kr/w/climate/statistics/regional-char.do?area=2>
- 소방청 공공데이터포털(국가화재정보시스템) 화재 발생 자료, <https://www.data.go.kr>
- 산림청, 2024 산불통계연보, <https://www.forest.go.kr/kfswweb/kfi/kfs/frfr/selectFrfrStats.do>
- 산림청, 울진·삼척 산불피해지 산림생태복원 기본계획, 2022, https://nfsv.forest.go.kr/kfs/images/data/down/sb_7_06.pdf
- 행정안전부, 2019년 강원도 산불 피해 현황 및 복구 계획, 2019.
- e-나라지표, 산불 발생 및 피해 현황, https://www.index.go.kr/unity/potal/main/EachDtlPageDetail.do?idx_cd=1309
- IMEN 415 (Spring 2026) Slides: PCA, MLR, GLM.